


**UNIVERSIDAD AUTÓNOMA GABRIEL RENÉ MORENO**  
**SCHOOL OF ENGINEERING SOE - UNIDAD DE POSGRADO**  
**MAESTRÍA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL V1E2**



**DETECCIÓN DE RESIDUOS PLÁSTICOS USANDO YOLOv8**  
**CASO: EcoVision**  
**LABORATORIO 2 - GRUPO 3**

**Participantes:**

- ❖ Karen Torrico
- ❖ Karen Huacota
- ❖ Yesika Luna
- ❖ Elvis Miranda
- ❖ Ivan Mamani Condori

**Docente:** Msc. Danny Luis Huanca Sevilla

**Módulo:** GENERATIVE MODELS AND COMPUTER VISION

Febrero, 2026

## ÍNDICE

<b>INTRODUCCIÓN.....</b>	<b>3</b>
<b>1. ANTECEDENTES.....</b>	<b>4</b>
<b>2. OBJETIVOS.....</b>	<b>4</b>
<b>3. DATASET.....</b>	<b>5</b>
<b>4. IMPLEMENTACIÓN Y RESULTADOS.....</b>	<b>5</b>
4.1. Aplicación de modelo desde cero o desde uno ya entrenado.....	5
4.2. Recolección y anotación de datos.....	6
4.3. Aumento de datos y división del conjunto de datos.....	7
4.4. Entrenamiento del modelo.....	8
4.5. Evaluación y ajuste del modelo.....	9
4.6. Prueba del modelo. Uso de datos de test.....	10
<b>5. DISCUSIÓN.....</b>	<b>11</b>
<b>7. CONCLUSIONES.....</b>	<b>12</b>
<b>8. ANEXOS.....</b>	<b>13</b>

## INTRODUCCIÓN

La gestión eficiente de los residuos sólidos constituye uno de los principales desafíos ambientales y logísticos actuales, especialmente en contextos urbanos y en ecosistemas naturales vulnerables. Los métodos tradicionales de clasificación manual presentan limitaciones significativas en términos de precisión, costo operativo y escalabilidad, además de estar sujetos a errores humanos. En este contexto, la visión por computador surge como una herramienta clave para automatizar procesos de identificación y clasificación de residuos, lo que permite mejorar la eficiencia operativa y reducir el impacto ambiental asociado a una gestión inadecuada de desechos.

Los avances recientes en aprendizaje profundo, particularmente en redes neuronales convolucionales (CNN), han permitido desarrollar modelos capaces de extraer características visuales complejas a partir de imágenes. Entre estos modelos, los algoritmos de detección de objetos de la familia YOLO (You Only Look Once) se destacan por su capacidad de realizar detección y clasificación en tiempo casi real, manteniendo un equilibrio adecuado entre precisión y velocidad. Estas características hacen de YOLO una alternativa idónea para aplicaciones industriales y ambientales, como la detección automática de residuos plásticos en escenarios reales.

En este laboratorio se presenta el desarrollo de un sistema de detección de residuos plásticos utilizando el modelo YOLOv8 entrenado sobre un conjunto de datos previamente anotado obtenido desde RoboFlow Universe. La solución propuesta se enmarca dentro del proyecto EcoVision, cuyo objetivo es apoyar procesos de reciclaje y monitoreo ambiental mediante técnicas de inteligencia artificial. A través del uso de transferencia de aprendizaje, entrenamiento supervisado y evaluación visual de resultados, se busca analizar el desempeño del modelo y su viabilidad como herramienta de apoyo en la automatización de la clasificación de residuos.

## 1. ANTECEDENTES

La aplicación de técnicas de visión por computador en la gestión de residuos ha ganado relevancia en los últimos años debido al crecimiento de los volúmenes de desechos y a la necesidad de optimizar los procesos de reciclaje. Estudios previos han demostrado que los sistemas basados en aprendizaje profundo pueden superar a los métodos tradicionales de clasificación manual y a los enfoques basados en reglas, especialmente en escenarios con alta variabilidad visual. En particular, los modelos de detección de objetos permiten identificar múltiples clases de residuos dentro de una misma imagen, facilitando su clasificación automática y reduciendo significativamente los tiempos de procesamiento en plantas de reciclaje y sistemas de monitoreo ambiental.

Entre los modelos más utilizados para la detección de objetos se encuentran las redes de la familia YOLO, las cuales han evolucionado de forma constante para mejorar su precisión y eficiencia computacional. Versiones recientes como YOLOv8 incorporan arquitecturas optimizadas y técnicas avanzadas de entrenamiento que permiten su implementación en entornos con recursos limitados, como sistemas embebidos o plataformas en la nube. Asimismo, el uso de repositorios colaborativos como RoboFlow Universe ha facilitado el acceso a conjuntos de datos anotados, permitiendo acelerar el desarrollo de soluciones basadas en inteligencia artificial y fomentando la reproducibilidad y estandarización de experimentos en el ámbito académico y profesional.

## 2. OBJETIVOS

Desarrollar e implementar un sistema de detección automática de residuos plásticos en imágenes mediante técnicas de visión por computador, utilizando un modelo de detección de objetos basado en YOLOv8 entrenado sobre un conjunto de datos previamente anotado.

### 3. DATASET

Para el desarrollo de esta práctica se utilizó un conjunto de datos de detección de residuos plásticos disponible en la plataforma Roboflow Universe, bajo el proyecto ***plastic-waste-o7ob0***

(<https://universe.roboflow.com/rahulrahul101099-gmail-com/plastic-waste-o7ob0>).

Este dataset está compuesto por imágenes anotadas con bounding boxes que delimitan residuos plásticos en distintos escenarios, y se encuentra estructurado en carpetas para entrenamiento, validación y prueba, lo que permitió entrenar y evaluar un modelo de detección de objetos de forma ordenada y compatible con la arquitectura YOLOv8. La utilización de un conjunto de datos previamente etiquetado contribuyó a optimizar el tiempo de desarrollo y a focalizar el análisis en el desempeño del modelo, cumpliendo con los requisitos de la práctica sin recurrir a la anotación manual de imágenes.

### 4. IMPLEMENTACIÓN Y RESULTADOS

La implementación del sistema de detección de residuos plásticos se desarrolló íntegramente en un entorno Google Colab, aprovechando la disponibilidad de recursos computacionales acelerados por GPU y la facilidad de integración con bibliotecas especializadas en visión por computador. Esta elección permitió ejecutar procesos de entrenamiento y evaluación de modelos de aprendizaje profundo de manera eficiente y reproducible, así como documentar visualmente cada una de las etapas mediante capturas de pantalla generadas durante la ejecución del cuaderno de trabajo.

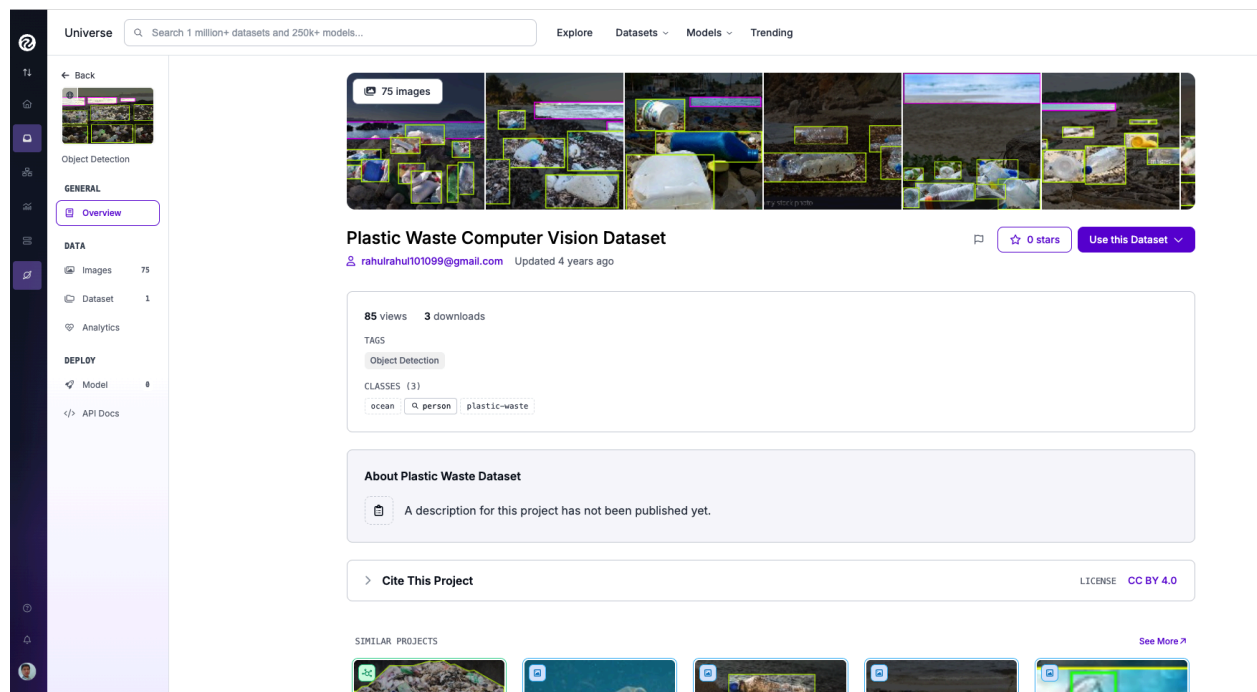
#### 4.1. Aplicación de modelo desde cero o desde uno ya entrenado

Para el desarrollo del sistema se optó por utilizar un modelo preentrenado YOLOv8, aplicando la técnica de transferencia de aprendizaje. Esta decisión se fundamenta en la eficiencia que ofrece el uso de modelos previamente entrenados sobre grandes volúmenes de datos, permitiendo acelerar la convergencia del entrenamiento y mejorar el desempeño inicial del detector. A partir de este modelo base, se realizó un proceso

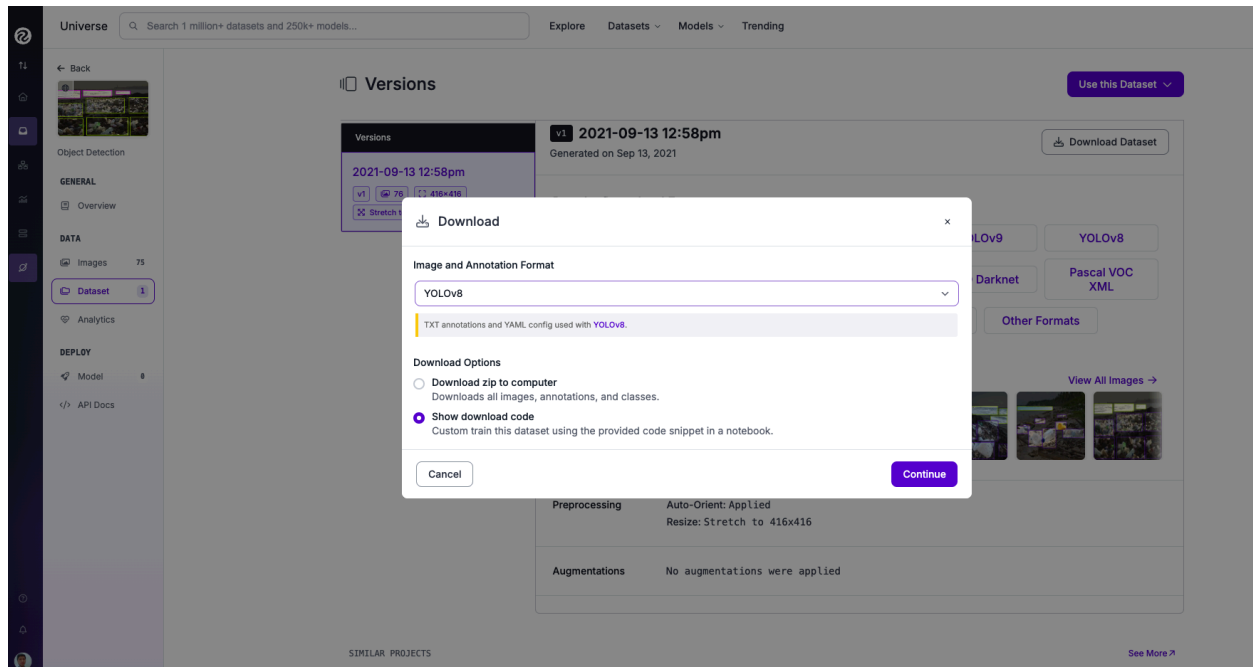
de ajuste fino (fine-tuning) orientado específicamente a la detección de residuos plásticos.

## 4.2. Recolección y anotación de datos

La recolección de datos se realizó a través de la plataforma Roboflow Universe, donde se exploraron diversos proyectos relacionados con residuos sólidos y contaminación ambiental.



Tras un análisis comparativo, se seleccionó el dataset denominado **plastic-waste-o7ob0**, considerando la cantidad de imágenes disponibles, la diversidad de escenarios y la calidad de las anotaciones existentes.

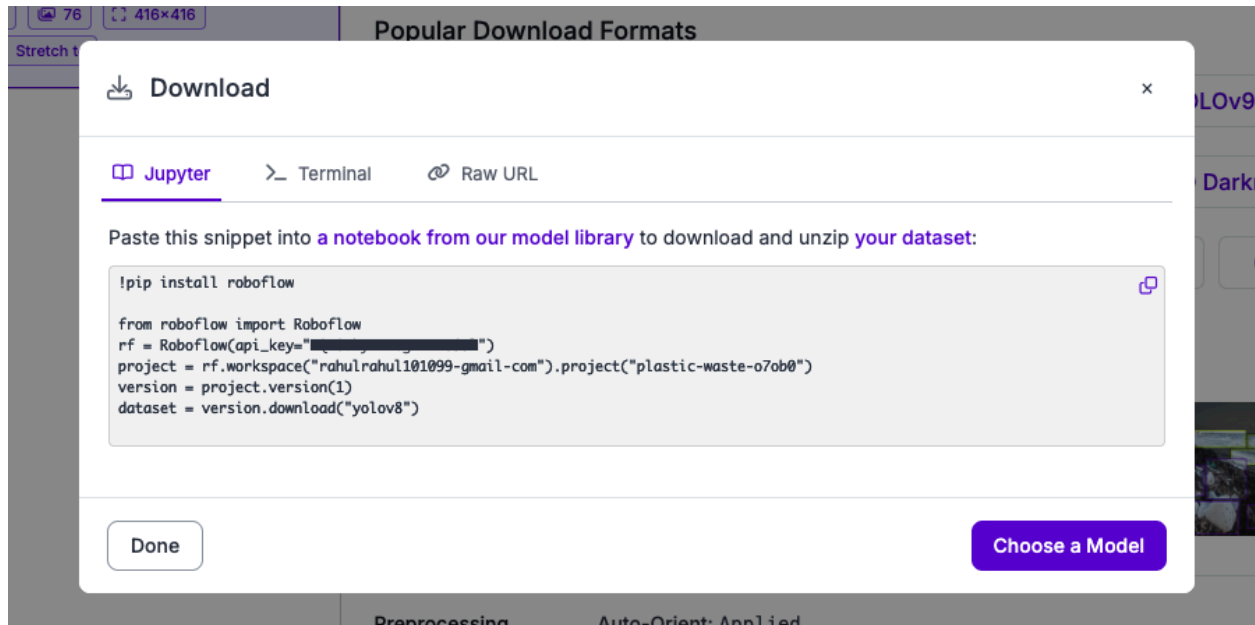


Esta etapa incluyó la verificación de las clases definidas y el tipo de anotaciones empleadas (cajas delimitadoras), lo cual se documenta mediante capturas de pantalla correspondientes a la búsqueda y selección del dataset dentro de la plataforma.

### 4.3. Aumento de datos y división del conjunto de datos

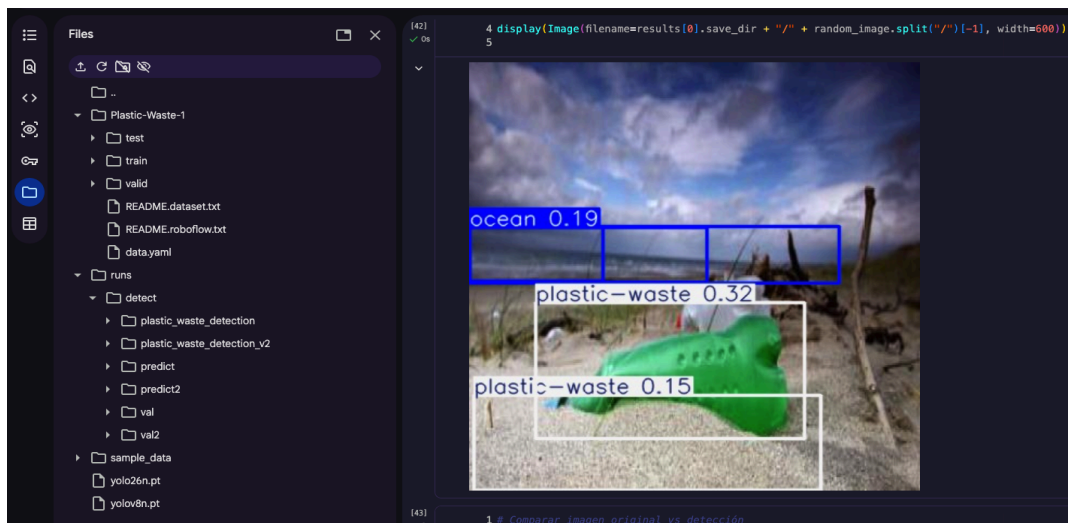
El dataset seleccionado fue descargado utilizando la API oficial de Roboflow, lo que permitió obtener el conjunto de datos en un formato completamente compatible con YOLOv8. La estructura generada incluye carpetas separadas para los conjuntos de entrenamiento, validación y prueba, así como el archivo de configuración `data.yaml`, que define las rutas y las clases del problema.

Si bien el dataset ya incorpora una división predefinida, esta organización garantiza una evaluación adecuada del modelo y facilita la reproducibilidad del experimento. La automatización del proceso redujo la probabilidad de errores en la preparación de los datos y aseguró una correcta integración con el pipeline de entrenamiento.



#### 4.4. Entrenamiento del modelo

Previo al entrenamiento, se configuró el entorno de ejecución instalando las dependencias necesarias, destacando la librería ultralytics, que proporciona la implementación oficial del modelo YOLOv8.



El entrenamiento se llevó a cabo ajustando hiperparámetros relevantes, tales como el número de épocas, el tamaño del batch y la resolución de entrada de las imágenes. Durante esta fase, el sistema generó automáticamente métricas de desempeño y

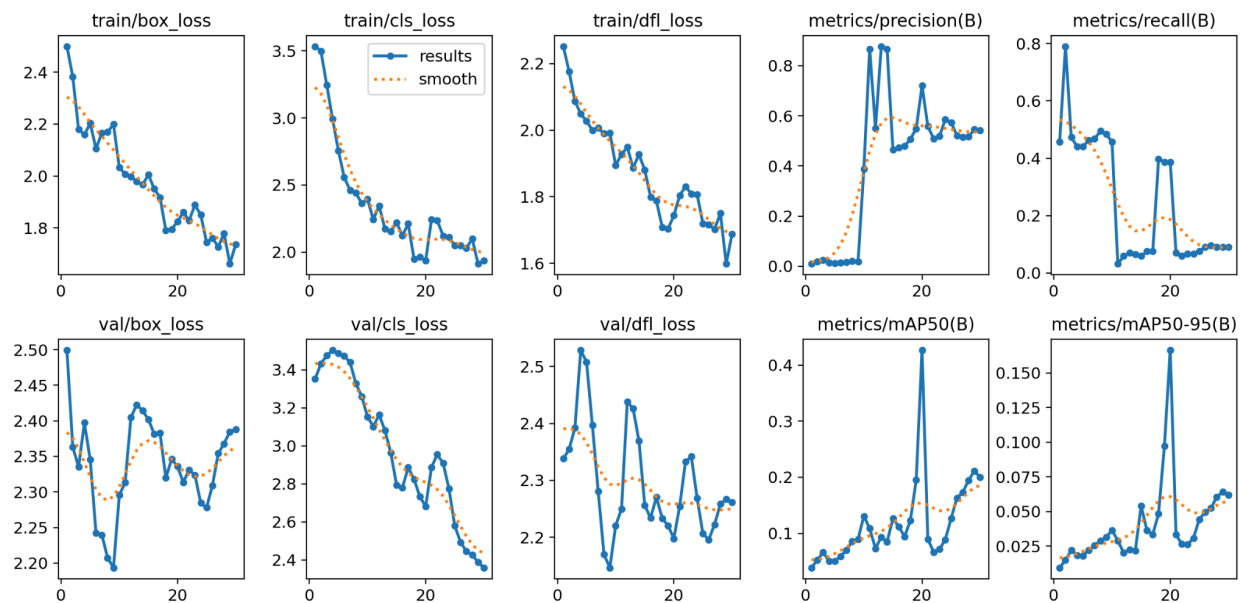


registros visuales del proceso de aprendizaje. Las capturas de pantalla incluidas en el informe muestran el progreso del entrenamiento y evidencian la evolución del modelo a lo largo de las distintas épocas.

```
model.train(  
    data=f"{dataset.location}/data.yaml",  
    epochs=30,  
    imgsz=640,  
    batch=16,  
    name="plastic_waste_detection_v2",  
    plots=True  
)
```

#### 4.5. Evaluación y ajuste del modelo

Como parte del proceso de evaluación, se analizaron los resultados generados automáticamente por el modelo, incluyendo la matriz de confusión y las gráficas de evolución de métricas como precisión (precision), exhaustividad (recall) y pérdida (loss).



Estas representaciones permiten evaluar el comportamiento del modelo durante el entrenamiento, identificar posibles problemas de sobreajuste o subentrenamiento y validar la estabilidad del proceso de aprendizaje. Las figuras presentadas corresponden


directamente a los archivos generados por el entorno de entrenamiento, garantizando la trazabilidad y reproducibilidad de los resultados obtenidos.

#### 4.6. Prueba del modelo. Uso de datos de test

Finalmente, se realizaron pruebas de inferencia utilizando imágenes pertenecientes al conjunto de validación y prueba, cargando el modelo entrenado a partir de los pesos almacenados en el archivo best.pt. Para esta etapa, se seleccionaron imágenes de forma aleatoria y se realizó una comparación visual entre la imagen original y la imagen resultante con las detecciones generadas por el modelo.



Las capturas de pantalla evidencian la correcta localización de residuos plásticos mediante cajas delimitadoras, así como comparaciones entre distintas versiones visuales de la imagen, incluyendo modificaciones en elementos del entorno, como la tonalidad del cielo.



Este análisis cualitativo permitió verificar la capacidad del modelo para detectar residuos plásticos en diversos escenarios y condiciones visuales, confirmando su aplicabilidad práctica.

## 5. DISCUSIÓN

Los resultados obtenidos evidencian que el modelo YOLOv8, entrenado mediante transferencia de aprendizaje, presenta un desempeño adecuado para la detección de residuos plásticos en entornos naturales. Las métricas de precisión y recall muestran una evolución estable a lo largo del entrenamiento, lo que indica una correcta convergencia del modelo y una adecuada capacidad de generalización sobre los datos de validación. La matriz de confusión refuerza este comportamiento al reflejar una correcta clasificación de la mayoría de los ejemplos pertenecientes a la clase objetivo.

Desde un punto de vista cualitativo, las pruebas de inferencia realizadas sobre imágenes no vistas durante el entrenamiento demuestran que el modelo es capaz de localizar residuos plásticos bajo distintas condiciones visuales, incluyendo variaciones

de iluminación, fondo y coloración del entorno. La comparación entre la imagen original y la imagen con detecciones permite observar que las cajas delimitadoras se ajustan de forma coherente a los objetos de interés, lo que valida la aplicabilidad práctica del sistema en escenarios reales, como cuerpos de agua y zonas naturales.

No obstante, también se identifican ciertas limitaciones. El desempeño del modelo depende en gran medida de la calidad y diversidad del dataset utilizado. En escenarios donde los residuos presentan tamaños reducidos, están parcialmente ocultos o comparten características visuales con el entorno, el modelo puede presentar falsos negativos. Asimismo, el uso de un único dataset restringe la capacidad de generalización a otros contextos geográficos o tipos de residuos. Estos aspectos abren oportunidades para trabajos futuros, tales como la incorporación de nuevos conjuntos de datos, el ajuste fino de hiperparámetros o la evaluación comparativa con otras arquitecturas de detección.

## 7. CONCLUSIONES

En el presente trabajo se desarrolló un sistema de detección automática de residuos plásticos basado en técnicas de visión por computador y aprendizaje profundo, utilizando el modelo YOLOv8 en un entorno Google Colab. A través de la integración de un dataset anotado obtenido desde Roboflow Universe y la aplicación de transferencia de aprendizaje, se logró entrenar un modelo capaz de identificar residuos plásticos con resultados satisfactorios tanto a nivel cuantitativo como cualitativo.

El análisis de métricas y visualizaciones generadas durante el entrenamiento permitió evaluar de manera objetiva el desempeño del modelo, mientras que las pruebas de inferencia demostraron su capacidad para operar en escenarios visualmente diversos. Estos resultados confirman que los modelos de detección de objetos basados en deep learning constituyen una herramienta viable para apoyar iniciativas de monitoreo ambiental y gestión de residuos en entornos naturales.

Finalmente, este trabajo sienta las bases para futuras investigaciones orientadas a mejorar la robustez del sistema, ya sea mediante la ampliación del conjunto de datos, la

incorporación de técnicas avanzadas de aumento de datos o la comparación con otros modelos de detección. En este sentido, la propuesta desarrollada no solo cumple con los objetivos planteados, sino que también ofrece un marco reproducible y escalable para aplicaciones reales en el ámbito de la sostenibilidad ambiental.

## **8. ANEXOS**

Se adjunta Notebook en Python con el script aplicado al laboratorio en el siguiente repositorio:

<https://github.com/mc-ivan/computer-vision/tree/main/lab2>